



Année universitaire 2025-2026

Encadré par:
Pr. Bakher Zine
Elabidine

Réaliséé par:
Boubrahim Sara

Remerciement :

Nous souhaitons tout d'abord exprimer notre profonde gratitude envers l'École Nationale de Commerce et de Gestion de Settat pour son engagement indéfectible en faveur de l'excellence académique et pour son soutien constant à notre développement personnel et professionnel. L'école constitue véritablement un phare d'innovation pédagogique, nous offrant des opportunités uniques de mettre en pratique nos connaissances à travers des projets concrets. C'est grâce à cette approche novatrice que nous avons pu acquérir des compétences essentielles et nous préparer efficacement à relever les défis du marché du travail.

Nous tenons également à exprimer notre sincère reconnaissance envers notre cher professeur Bakher Zine Elabidine, pour sa guidance précieuse, ses conseils éclairés et son soutien constant tout au long de ce semestre. Nous avons grandement apprécié ses retours constructifs, qui nous ont permis de progresser et d'améliorer la qualité de notre travail. Sa bienveillance et son professionnalisme ont créé un environnement d'apprentissage particulièrement favorable.

Table des matières

Introduction générale.....	4
-----------------------------------	----------

Partie 1 – Exploration et analyse des données

1.Introduction.....	5
2.Chargement et inspection des données.....	6
3.Analyse univariée.....	7
4.Analyse bivariée.....	10
5.Préparation des données.....	13.

Partie 2 – Modélisation et prédiction

1.Introduction.....	14
2.Régression logistique.....	15
3.Random Forest Classifier.....	17
4.Optimisation des hyperparamètres.....	19
5.Analyse des erreurs.....	21

Partie 3 – Segmentation des clients

1.Introduction.....	22
2.Méthodologie de segmentation.....	23
3.Résultats et interprétation des clusters-Profiles clients identifiés.....	26

Partie 4 – Recommandations et conclusion

1.Recommandations stratégiques.....	29
2.Limites du projet et perspectives.....	30

Conclusion générale.....	32
---------------------------------	-----------

Introduction Générale:

Dans un contexte économique marqué par une concurrence accrue et des exigences réglementaires de plus en plus strictes, la gestion du risque de crédit constitue un enjeu stratégique majeur pour les institutions financières. Les banques doivent en effet concilier deux objectifs parfois contradictoires : accorder des crédits afin de soutenir leur croissance commerciale, tout en maîtrisant le risque de défaut de paiement susceptible d'affecter leur rentabilité et leur stabilité financière.

Avec l'essor des technologies numériques et la disponibilité croissante des données clients, les méthodes traditionnelles d'évaluation du risque montrent aujourd'hui leurs limites. L'exploitation des techniques de Data Science et de Machine Learning offre ainsi de nouvelles perspectives pour analyser finement le comportement des clients, identifier les facteurs déterminants du risque et améliorer la qualité des décisions d'octroi de crédit.

C'est dans ce cadre que s'inscrit le présent projet, réalisé au sein du département Analytics d'une grande banque marocaine. La mission confiée consiste à concevoir un système d'aide à la décision permettant d'évaluer le risque de défaut de paiement des clients à partir de données socio-démographiques, financières et comportementales. L'objectif est de fournir à la direction de la banque des outils analytiques fiables, interprétables et opérationnels, capables de réduire les pertes financières tout en préservant les opportunités commerciales.

Ce rapport présente l'ensemble de la démarche suivie, depuis l'exploration et l'analyse descriptive des données jusqu'au développement de modèles prédictifs de classification du risque. Il intègre également une segmentation des clients afin d'identifier des profils homogènes et de formuler des recommandations stratégiques adaptées. Les résultats obtenus visent à démontrer la valeur ajoutée des approches basées sur la Data Science dans l'amélioration de la gestion du risque bancaire et dans le soutien à la prise de décision managériale.

Partie 1 – Exploration et Analyse des Données

1.Introduction :

L'exploration des données constitue une étape fondamentale dans tout projet de Data Science, en particulier dans un contexte bancaire où les décisions reposent sur des enjeux financiers et stratégiques importants. Avant toute modélisation prédictive, il est indispensable de comprendre la structure du jeu de données, la qualité des informations disponibles ainsi que les relations existantes entre les variables explicatives et la variable cible représentant le risque de défaut.

Cette première partie vise à analyser en profondeur le profil des clients de la banque à travers une exploration descriptive et analytique des données. Elle permet d'identifier les tendances générales, de détecter d'éventuelles anomalies ou valeurs aberrantes, et d'évaluer la cohérence des variables socio-démographiques, financières et comportementales. Une attention particulière est portée à la qualité des données, notamment en termes de distributions, de déséquilibres et de corrélations.

Les visualisations jouent un rôle central dans cette phase exploratoire. Elles facilitent la compréhension des comportements clients, mettent en évidence les facteurs potentiellement liés au risque de défaut et soutiennent l'interprétation des résultats d'un point de vue business. Chaque graphique est ainsi conçu dans une logique analytique, avec pour objectif de produire des insights exploitables pour la suite du projet.

Enfin, cette analyse exploratoire permet de dégager des premiers enseignements stratégiques sur les profils à risque et sur les variables les plus discriminantes. Ces insights constituent la base des choix méthodologiques effectués dans les parties suivantes, notamment en matière de modélisation prédictive et de segmentation client.

2.Chargement et Inspection Initiale

Avant d'entamer toute analyse approfondie ou modélisation, il est essentiel de procéder à une inspection initiale du jeu de données. Cette étape permet de vérifier la structure du dataset, d'identifier les types de variables, d'évaluer la qualité des données et de détecter d'éventuelles valeurs manquantes. Elle constitue une base indispensable pour garantir la fiabilité des analyses et orienter les choix méthodologiques des étapes suivantes.

Pour réaliser cette inspection initiale, nous utilisons la bibliothèque pandas afin de :

- Charger le dataset dans un DataFrame (`pd.read_csv`).
- Afficher les 10 premières lignes pour visualiser un aperçu des données (`df.head(10)`).
- Consulter les informations générales sur les colonnes, types de données et non-nullité (`df.info()`).
- Calculer les statistiques descriptives pour les variables numériques (`df.describe()`).
- Identifier les valeurs manquantes et leur fréquence dans le jeu de données (`df.isnull().sum()`).

2.1. Analyse des résultats :

Le jeu de données contient 4 000 clients, décrits par des variables démographiques, financières et comportementales. L'âge des clients varie de 22 à 69 ans, avec une moyenne d'environ 46 ans, ce qui traduit une population majoritairement active. Le nombre d'enfants et de crédits actifs reste modéré, conforme aux pratiques bancaires marocaines.

Les variables financières, notamment le salaire mensuel et l'épargne totale, présentent une forte dispersion et une distribution asymétrique. L'épargne varie de 5 à plus de 215 000, suggérant la présence de clients à hauts revenus ou patrimoines élevés. Certaines variables financières clés, comme le salaire, l'épargne et le nombre de crédits actifs, comportent environ 120 valeurs manquantes, ce qui ne peut être ignoré sans risquer un biais d'échantillonnage.

Globalement, les valeurs observées sont cohérentes : aucune valeur négative ou aberrante n'a été détectée pour les variables critiques, le score de crédit est compris entre 300 et 850, et la variable cible `risque_defaut` est binaire, avec un taux moyen de défaut de 39,5 %. Le dataset est légèrement déséquilibré mais exploitable, avec toutefois une attention particulière à porter aux outliers identifiés dans certaines variables financières.

2.2. Recommandations de préparation des données :

Avant toute modélisation, les variables catégorielles devront être encodées à l'aide du One-Hot Encoding, pour éviter une hiérarchisation artificielle des catégories et garantir la compatibilité avec les algorithmes de machine learning. Les outliers doivent être identifiés via des boxplots ou la méthode IQR, et traités selon leur impact potentiel sur le modèle.

Dans l'ensemble, le dataset est exploitable et cohérent, mais un nettoyage méthodique est indispensable pour assurer la fiabilité du futur système d'aide à la décision sur le risque de défaut bancaire.

3. Analyse Univariée :

Afin de mieux comprendre le profil des clients et d'identifier les facteurs de risque, une analyse exploratoire des variables est réalisée. Elle porte sur l'étude des variables numériques (distributions et valeurs aberrantes), des variables catégorielles (répartition des clients par catégorie) ainsi que de la variable cible `risque_defaut` afin d'évaluer son équilibre.

Pour les variables numériques :

Pour chaque variable numérique, deux types de visualisations sont utilisés :

- Histogramme avec courbe de densité (KDE) afin d'observer la forme de la distribution (symétrie, asymétrie, concentration des valeurs).
- Boxplot, permettant d'identifier visuellement les valeurs aberrantes (outliers).

Par exemple, pour la variable `âge`, la distribution est analysée à l'aide d'un histogramme et d'un boxplot :

```
sns.histplot(df['age'], bins=30, kde=True)  
sns.boxplot(x=df['age'])
```

Les valeurs aberrantes sont ensuite détectées de manière quantitative à l'aide de la méthode de l'écart interquartile (IQR), définie par les premier et troisième quartiles (Q1 et Q3) :

```
Q1 = df['age'].quantile(0.25)
Q3 = df['age'].quantile(0.75)
IQR = Q3 - Q1
```

Les observations situées en dehors de l'intervalle $[Q1 - 1.5 \times IQR; Q3 + 1.5 \times IQR]$ sont considérées comme des valeurs aberrantes. Cette même méthodologie est appliquée aux variables salaire_mensuel, epargne_totale et score_credit.

Pour les variables catégorielles :

Les variables catégorielles étant encodées en one-hot encoding, leur analyse repose sur l'agrégation des colonnes correspondantes. Par exemple, pour la variable ville, les colonnes commençant par ville_ sont sélectionnées, puis le nombre et le pourcentage de clients par modalité sont calculés :

```
villes = [col for col in df.columns if col.startswith('ville_')]
df[villes].sum().plot(kind='bar')
print(df[villes].sum()/len(df)*100)
```

La même approche est appliquée aux variables profession et situation_familiale, permettant d'évaluer l'équilibre des catégories et la diversité des profils clients.

3.1.Analyse des résultats :

Variables numériques :

L'analyse de la variable âge montre une distribution homogène et réaliste, sans présence de valeurs aberrantes. Les âges observés correspondent à un profil client bancaire classique, ce qui confirme la cohérence de cette variable.

En revanche, la variable salaire_mensuel présente 16 valeurs aberrantes, correspondant à des niveaux de revenus très éloignés de la majorité des observations. Ces cas peuvent représenter soit des profils à très hauts revenus, soit des erreurs de saisie. Une analyse complémentaire est donc nécessaire pour juger de leur pertinence.

La variable épargne_totale affiche un nombre plus important de valeurs aberrantes (177 observations), traduisant une forte hétérogénéité des comportements d'épargne. Cette dispersion reflète probablement la coexistence de clients disposant d'une faible capacité d'épargne et de clients à fort patrimoine.

Enfin, le `score_credit` présente 415 valeurs aberrantes, correspondant à des scores extrêmement faibles ou élevés. Bien que ces valeurs soient informatives du point de vue métier, elles peuvent influencer de manière significative les modèles prédictifs si elles ne sont pas traitées correctement.

Globalement, la présence de valeurs aberrantes dans plusieurs variables numériques peut affecter la stabilité et la robustesse des modèles, ce qui justifie la mise en place de techniques adaptées de traitement des outliers.

Variables catégorielles :

L'analyse des variables catégorielles révèle des répartitions globalement équilibrées. La variable `ville` présente une distribution relativement homogène, chaque modalité représentant environ 9,3 % à 11,1 % de l'échantillon total. Cette homogénéité est favorable à la modélisation, car elle limite les biais liés à une surreprésentation géographique.

De même, la variable `profession` affiche une répartition équilibrée, avec des proportions comprises entre 9,4 % et 10,6 %, traduisant une diversité satisfaisante des profils professionnels. La variable `situation_familiale` est également bien répartie, avec des proportions proches pour les principales catégories (entre 24,2 % et 26,0 %). Toutefois, certaines modalités rares ou absentes pourraient être regroupées dans une catégorie « Autre » ou « Inconnu » si nécessaire.

Analyse de la variable cible : `risque_defaut`

L'étude de la distribution de la variable cible `risque_defaut` montre que la majorité des clients ne présentent pas de défaut de paiement, tandis qu'environ 40 % sont classés comme présentant un risque de défaut. Le jeu de données présente ainsi un déséquilibre modéré entre les deux classes. Bien que ce déséquilibre ne soit pas extrême, il devra être pris en compte lors de la modélisation afin d'éviter des biais dans les performances des modèles de classification.

3.2. Qualité des données et cohérence :

La qualité globale des données est satisfaisante, mais nécessite certaines vérifications. La présence de valeurs manquantes doit être systématiquement contrôlée à l'aide de `df.isnull().sum()`.

Les variables numériques présentant des valeurs extrêmes doivent être examinées afin de distinguer les valeurs réalistes des anomalies. Par ailleurs, bien que les variables catégorielles soient encodées, certaines lignes entièrement nulles peuvent indiquer des informations manquantes ou non renseignées.

3.3.Actions de nettoyage et de prétraitement recommandées :

Plusieurs actions sont recommandées avant la phase de modélisation :

- Traitement des valeurs manquantes : imputation par la moyenne ou la médiane pour les variables numériques, et création d'une modalité « Inconnu » pour les variables catégorielles.
- Gestion des valeurs aberrantes : analyse approfondie des outliers afin de distinguer les cas réalistes des anomalies, suivie de techniques adaptées telles que le clipping, la transformation ou l'exclusion contrôlée.
- Cohérence des variables catégorielles : vérification des colonnes one-hot pour détecter d'éventuelles lignes entièrement nulles et regroupement des modalités rares ou inconnues.
- Normalisation / standardisation : mise à l'échelle des variables numériques à l'aide de StandardScaler, afin d'assurer une contribution équitable des variables lors de la modélisation et d'améliorer les performances des algorithmes.

4.Analyse Bivariée :

Après l'analyse individuelle des variables, il est essentiel d'étudier les relations existantes entre les caractéristiques des clients et le risque de défaut de paiement. Cette étape vise à identifier les variables les plus fortement associées à la variable cible `risque_defaut`, à comparer les comportements moyens des clients selon leur statut de défaut et à analyser l'impact des variables catégorielles sur le taux de défaut. L'objectif est de dégager des liens statistiques et des insights métier pertinents, susceptibles d'orienter la sélection des variables et les choix méthodologiques lors de la phase de modélisation prédictive.

4.1. Analyse des résultats :

Analyse des corrélations entre variables numériques et risque de défaut :

L'analyse de la matrice de corrélation met en évidence l'existence de relations significatives entre certaines variables numériques et la variable cible `risque_defaut`. Parmi l'ensemble des variables étudiées, trois indicateurs ressortent comme étant les plus fortement associés au risque de défaut.

La variable nombre de crédits actifs (`nbr_credits_actifs`) présente la corrélation la plus élevée avec le risque de défaut, avec un coefficient de 0,63. Cette relation positive indique que plus un client détient de crédits en cours, plus la probabilité de défaut augmente. Ce résultat est cohérent avec la logique bancaire, car une accumulation d'engagements financiers accroît la charge de remboursement et fragilise la capacité financière du client.

Le score de crédit (`score_credit`) affiche une corrélation modérée de 0,45 avec le risque de défaut. Cette association confirme le rôle central du score de crédit dans l'évaluation du risque. Toutefois, l'interprétation précise de cette relation dépend de la définition du score utilisée, notamment du sens dans lequel une valeur élevée ou faible traduit un niveau de risque plus important.

Enfin, le salaire mensuel (`salaire_mensuel`) présente une corrélation modérée de 0,34 avec le risque de défaut. Cette relation suggère que les clients disposant de revenus plus faibles sont, en moyenne, plus exposés au risque de non-remboursement, ce qui est conforme aux attentes économiques et financières.

4.2. Analyse comparative des variables numériques selon le risque de défaut :

Score de crédit et risque de défaut :

L'analyse comparative du score de crédit selon le statut de défaut révèle une différenciation nette entre les deux groupes de clients. Les clients sans défaut (`risque_defaut = 0`) présentent des scores de crédit globalement élevés et concentrés autour d'une médiane élevée, traduisant une bonne solvabilité et une faible dispersion des scores.

À l'inverse, les clients en situation de défaut (`risque_defaut = 1`) affichent une distribution beaucoup plus dispersée, avec une médiane plus faible et des valeurs pouvant atteindre des niveaux très bas. Cette observation met en évidence une relation négative marquée entre le score de crédit et le risque de défaut : plus le score est faible, plus la probabilité de défaut est élevée.

Salaire mensuel et risque de défaut

L'analyse du salaire mensuel selon le statut de défaut montre également des différences notables, bien que moins prononcées que pour le score de crédit. Les clients sans défaut présentent un salaire médian plus élevé et une distribution relativement concentrée, malgré la présence de quelques valeurs élevées.

En revanche, les clients en défaut affichent un salaire médian plus faible et une dispersion plus importante. Il convient toutefois de noter que certains clients à revenus élevés présentent également un défaut, ce qui indique que le salaire, pris isolément, ne suffit pas à expliquer le comportement de remboursement. Ainsi, bien qu'un revenu plus faible soit associé à un risque de défaut plus élevé, cette variable doit être combinée à d'autres indicateurs pour une évaluation plus fiable du risque.

4.3. Analyse des relations catégorielles avec le risque de défaut :

L'analyse du taux de défaut selon la ville de résidence met en évidence des disparités géographiques significatives. Certaines villes, notamment Agadir, Tanger et Kénitra, présentent les taux de défaut les plus élevés, avoisinant 40 %. Ces différences peuvent refléter des facteurs locaux tels que les conditions économiques régionales, la dynamique du marché de l'emploi ou le coût de la vie, influençant la capacité de remboursement des clients.

L'étude du risque de défaut selon la profession révèle que la catégorie des employés affiche le taux de défaut le plus élevé, estimé à environ 43 %. Ce résultat suggère que cette catégorie professionnelle est particulièrement exposée au risque de non-remboursement. Cette vulnérabilité peut s'expliquer par des revenus généralement fixes et relativement limités, offrant peu de flexibilité financière face aux aléas économiques ou aux dépenses imprévues.

Enfin, l'analyse par situation familiale indique que les personnes divorcées présentent le taux de défaut le plus élevé, proche de 41 %. Cette observation souligne l'importance de la situation familiale dans l'évaluation du risque de crédit. Les individus divorcés peuvent être confrontés à des charges financières supplémentaires, telles que les pensions alimentaires, les dépenses liées aux enfants ou la perte d'un soutien financier, ce qui accroît leur vulnérabilité économique et, par conséquent, leur probabilité de défaut.

5.Préparation des Données

Avant de lancer la modélisation prédictive, il est essentiel de préparer le jeu de données afin d'assurer sa qualité et sa cohérence. Cette préparation inclut la gestion des valeurs manquantes, l'encodage des variables catégorielles, la séparation du dataset en ensembles d'apprentissage et de test, ainsi que la normalisation des variables numériques. Ces étapes permettent d'optimiser les performances des modèles et d'éviter les biais liés aux données.

5.1Analyse des résultats :

Après la préparation du jeu de données, plusieurs points clés se dégagent. La gestion des valeurs manquantes a permis de conserver l'ensemble des clients dans le dataset. Les variables numériques comme `salaire_mensuel` et `épargne_totale` ont été imputées par la médiane, réduisant l'impact des valeurs extrêmes, tandis que les variables catégorielles présentant des manques (`ville`, `profession`) ont été complétées par la catégorie "Inconnu". Cette approche assure que les modèles d'apprentissage disposent d'un maximum d'informations fiables, tout en minimisant les biais liés aux données manquantes.

L'encodage des variables catégorielles avec `OneHotEncoder` a transformé les catégories en variables binaires, évitant toute hiérarchisation artificielle. Cela permet aux modèles de machine learning de traiter correctement des attributs tels que `ville`, `profession` ou `situation_familiale`, améliorant ainsi la qualité de l'apprentissage et la précision des prédictions. La division du dataset en 80% pour l'apprentissage et 20% pour le test garantit que le modèle est entraîné sur un ensemble représentatif tout en conservant un échantillon indépendant pour évaluer sa performance, ce qui aide à détecter d'éventuels problèmes de surapprentissage.

La normalisation des variables numériques à l'aide de `StandardScaler` a transformé les données pour qu'elles aient une moyenne de 0 et un écart type de 1. Cette étape est essentielle pour les modèles sensibles à l'échelle des variables, tels que la régression logistique ou les méthodes basées sur les distances, et contribue à améliorer la convergence et la stabilité de l'apprentissage. Dans l'ensemble, ces étapes ont rendu le dataset exploitable pour la modélisation prédictive, en préservant l'information utile tout en réduisant les biais liés aux valeurs extrêmes ou aux différences d'échelle.

5.2 Recommandations professionnelles :

Même après traitement, certaines variables comme `salaire_mensuel`, `épargne_totale` ou `score_credit` présentent des valeurs extrêmes qui peuvent influencer les modèles. Il est donc recommandé de réaliser une analyse complémentaire pour déterminer si ces valeurs correspondent à des situations réelles ou à des anomalies de saisie.

La mise à jour régulière des données est également essentielle. Les informations des clients évoluent constamment, et un processus périodique de nettoyage et de vérification permettra de maintenir la qualité des données et la fiabilité des modèles prédictifs.

Il est par ailleurs conseillé de documenter toutes les transformations appliquées aux données (imputation, encodage, normalisation) afin d'assurer la reproductibilité et de faciliter la mise en production des modèles. Enfin, une validation continue des performances du modèle sur de nouvelles données permettra de détecter toute dérive et d'ajuster le preprocessing si nécessaire, garantissant ainsi des prédictions fiables sur le risque de défaut des clients

Partie 2 – Modélisation et Prédiction

1.Introduction :

À l'issue de l'analyse exploratoire des données, qui a permis d'identifier les principales caractéristiques des clients ainsi que les variables les plus associées au risque de défaut, cette deuxième partie se concentre sur le développement de modèles de Machine Learning destinés à prédire la probabilité de défaut de paiement. Cette phase constitue le cœur du projet, dans la mesure où elle vise à transformer les enseignements issus de l'analyse descriptive en outils prédictifs opérationnels.

L'objectif principal est d'évaluer et de comparer différentes approches de classification supervisée afin d'identifier le modèle le plus performant et le plus adapté au contexte bancaire. Dans un premier temps, un modèle de régression logistique est mis en place comme approche de référence, en raison de sa simplicité et de son interprétabilité. Il est ensuite comparé à un modèle plus avancé, le Random Forest Classifier, capable de capturer des relations non linéaires et des interactions complexes entre les variables.

Cette partie intègre également une étape d'optimisation des hyperparamètres à l'aide de la validation croisée, afin d'améliorer les performances prédictives du modèle retenu. Enfin, une analyse approfondie des erreurs de classification est menée pour comprendre les limites des modèles, identifier les profils mal classés et proposer des pistes d'amélioration concrètes. L'ensemble de ces analyses vise à fournir des résultats fiables, interprétables et exploitables pour la prise de décision bancaire.

2. Régression Logistique

Dans cette première approche de modélisation, la régression logistique est utilisée afin de prédire le risque de défaut de paiement des clients. Ce modèle constitue une référence classique en classification binaire, particulièrement appréciée dans le secteur bancaire pour sa simplicité, sa robustesse et son interprétabilité. L'objectif est d'évaluer sa capacité à discriminer les clients à risque des clients solvables, tout en identifiant les variables les plus influentes dans la décision de défaut.

2.1. Analyse des résultats :

La mise en œuvre de la régression logistique s'est déroulée selon une démarche structurée, conformément aux bonnes pratiques en Machine Learning.

Dans un premier temps, le dataset est chargé et préparé. La variable cible `risque_defaut` est séparée des variables explicatives. Les valeurs manquantes sont traitées en imputant la médiane pour les variables numériques et la modalité « Inconnu » pour les variables catégorielles, afin de préserver l'information disponible sans introduire de biais excessif.

Les variables catégorielles sont ensuite transformées par encodage one-hot à l'aide de `pd.get_dummies`, ce qui permet leur intégration dans un modèle mathématique. Les données sont ensuite divisées en ensembles d'entraînement et de test (80 % / 20 %) afin d'évaluer les performances du modèle sur des données non vues.

Étant donné que la régression logistique est sensible à l'échelle des variables, une standardisation des variables numériques est appliquée à l'aide de `StandardScaler`. Cette étape garantit que toutes les variables contribuent de manière équitable à l'apprentissage du modèle.

Le modèle de régression logistique est ensuite entraîné sur les données d'entraînement, puis utilisé pour générer des prédictions et des probabilités sur l'ensemble de test. Les performances sont évaluées à l'aide de plusieurs métriques : accuracy, matrice de confusion, precision, recall, F1-score et ROC-AUC. Enfin, les coefficients du modèle sont analysés afin d'identifier les variables les plus déterminantes dans la prédiction du risque de défaut.

Les résultats obtenus montrent que le modèle de régression logistique atteint une accuracy globale de 88 %, ce qui signifie que la majorité des clients sont correctement classés, qu'ils soient à risque ou non. Cette performance globale indique un bon niveau de fiabilité du modèle.

L'analyse détaillée par classe révèle une très bonne capacité du modèle à identifier les clients non défaillants ($\text{risque_defaut} = 0$), avec une précision de 88 % et un rappel de 92 %. Cela implique que peu de clients solvables sont incorrectement classés comme étant à risque, ce qui est essentiel pour limiter le rejet de bons clients.

Pour la classe des clients à risque ($\text{risque_defaut} = 1$), le modèle atteint une précision de 87 % et un rappel de 81 %. Bien que ces résultats soient satisfaisants, ils indiquent que certains clients réellement à risque ne sont pas détectés (faux négatifs), ce qui constitue un enjeu important dans un contexte bancaire.

2.2. Forces, limites et recommandations :

Forces du modèle :

- Modèle simple, robuste et facilement interprétable
- Bonnes performances globales (Accuracy élevée et ROC-AUC = 0,94)
- Identification claire des variables explicatives clés
- Visualisations pertinentes facilitant l'analyse (matrice de confusion, courbe ROC)

Limites :

- Déséquilibre modéré du dataset, entraînant un rappel perfectible pour la classe à risque
- Modèle linéaire ne capturant pas les interactions complexes entre variables
- Sensibilité aux valeurs extrêmes et à la qualité du prétraitement des données

2.3.Recommandations :

- Tester des modèles non linéaires plus avancés (Random Forest, Gradient Boosting)
- Ajuster le seuil de décision pour réduire les faux négatifs
- Introduire des techniques de pondération des classes ou de rééchantillonnage
- Combiner la régression logistique avec d'autres modèles dans une approche comparative

3.Random Forest Classifier

Après l'application de la régression logistique, un modèle de Random Forest Classifier est mis en œuvre afin d'améliorer la performance de prédiction du risque de défaut bancaire. La Random Forest est un algorithme d'apprentissage supervisé basé sur un ensemble d'arbres de décision, capable de modéliser des relations non linéaires et des interactions complexes entre les variables explicatives. L'objectif est d'évaluer si ce modèle offre de meilleures performances prédictives que la régression logistique, tout en identifiant les variables les plus déterminantes dans la décision de défaut.

3.1.Analyse des résultats :

La mise en place du modèle Random Forest suit une démarche rigoureuse et comparable à celle utilisée pour la régression logistique, afin de garantir une comparaison équitable.

Dans un premier temps, un modèle RandomForestClassifier est instancié avec les paramètres imposés par l'énoncé, notamment `n_estimators = 100`, correspondant au nombre d'arbres dans la forêt, et `random_state = 42` afin d'assurer la reproductibilité des résultats.

```
rf_model = RandomForestClassifier(n_estimators=100, random_state=42)
```

Le modèle est ensuite entraîné sur les données d'apprentissage à l'aide de la méthode `fit(X_train, y_train)`. Une fois l'apprentissage terminé, des prédictions de classes (`predict`) ainsi que des probabilités associées à la classe « client à risque » (`predict_proba`) sont générées sur l'échantillon de test.

Les performances du modèle sont évaluées à l'aide des mêmes métriques que pour la régression logistique : accuracy, matrice de confusion, precision, recall, F1-score et ROC-AUC, garantissant ainsi une comparaison cohérente entre les deux approches.

La matrice de confusion est visualisée sous forme de heatmap afin d'analyser les erreurs de classification, tandis que la courbe ROC permet d'évaluer la capacité discriminante du modèle sur différents seuils de décision.

Les résultats obtenus montrent que le modèle Random Forest atteint une accuracy très élevée, indiquant une excellente capacité globale de classification des clients. La matrice de confusion révèle une nette amélioration dans la détection des clients à risque, avec une réduction significative du nombre de faux négatifs par rapport à la régression logistique. Cet aspect est particulièrement crucial dans un contexte bancaire, où l'objectif principal est d'anticiper les défauts de paiement.

Le score ROC-AUC proche de 1 confirme l'excellente capacité discriminante du modèle. Cela signifie que la Random Forest distingue presque parfaitement les clients défaillants des clients solvables, indépendamment du seuil de décision retenu.

L'analyse des importances des variables montre que certaines caractéristiques jouent un rôle déterminant dans la prédiction du risque de défaut. Parmi les variables les plus influentes figurent notamment le nombre de crédits actifs, le salaire mensuel et le score de crédit. Ces résultats sont cohérents avec ceux observés lors de la régression logistique, ce qui renforce la crédibilité des conclusions. Toutefois, la Random Forest met davantage en évidence les interactions complexes entre ces variables, que la régression logistique ne peut pas capturer en raison de sa structure linéaire.

3.2. Analyse comparative : Régression Logistique vs Random Forest :

La comparaison des deux modèles met en évidence des différences importantes. La régression logistique présente l'avantage d'être simple et facilement interprétable, permettant d'expliquer clairement l'effet de chaque variable sur le risque de défaut. Cependant, ses performances restent limitées face à des relations non linéaires.

À l'inverse, la Random Forest offre des performances nettement supérieures sur l'ensemble des métriques, notamment en termes de rappel pour la classe des clients à risque et de ROC-AUC. Elle est donc plus adaptée à un objectif de prédiction pure, bien qu'elle soit moins interprétable et plus coûteuse en temps de calcul.

3.3.Recommandations finales :

Au regard des résultats obtenus, le modèle Random Forest est recommandé comme modèle principal de prédiction du risque de défaut bancaire, en raison de ses performances élevées et de sa capacité à réduire le risque de faux négatifs. Ce choix est particulièrement pertinent dans un contexte opérationnel où la priorité est la maîtrise du risque.

Néanmoins, la régression logistique conserve un intérêt stratégique en tant qu'outil d'explication et de communication auprès des décideurs et des managers. Une solution pratique consiste donc à utiliser la Random Forest pour la prise de décision automatisée, tout en s'appuyant sur la régression logistique pour l'interprétation des résultats et la justification des choix stratégiques.

4.Optimisation des Hyperparamètres :

Bien que le modèle Random Forest de base ait déjà montré d'excellentes performances en matière de prédiction du risque de défaut, il est méthodologiquement essentiel d'explorer l'optimisation de ses hyperparamètres. Cette étape vise à améliorer la robustesse et la capacité de généralisation du modèle, tout en réduisant le risque de surapprentissage. Pour ce faire, la méthode GridSearchCV est utilisée afin de tester plusieurs combinaisons d'hyperparamètres à l'aide d'une validation croisée à 5 folds.

4.1.Analyse des résultats :

L'optimisation débute par l'instanciation d'un modèle Random Forest sans paramètres spécifiques, à l'exception de `random_state = 42`, garantissant la reproductibilité des résultats.

```
rf = RandomForestClassifier(random_state=42)
```

Un ensemble d'hyperparamètres est ensuite défini à travers une grille de recherche (param_grid). Cette grille inclut le nombre d'arbres (n_estimators) ainsi que la profondeur maximale des arbres (max_depth), deux paramètres ayant un impact direct sur la complexité et la performance du modèle.

```
param_grid = {  
    'n_estimators': [50, 100],  
    'max_depth': [None, 10, 20]  
}
```

La fonction GridSearchCV est alors mise en œuvre avec une validation croisée à 5 folds (cv=5) et le score ROC-AUC comme métrique d'optimisation, ce choix étant particulièrement adapté aux problèmes de classification binaire déséquilibrée comme le risque de défaut bancaire

```
grid_search = GridSearchCV(  
    estimator=rf,  
    param_grid=param_grid,  
    cv=5,  
    scoring='roc_auc',  
    n_jobs=-1,  
    verbose=1  
)
```

Avant optimisation, le modèle Random Forest de base présentait déjà des performances exceptionnelles, avec une accuracy de 100 % et un score ROC-AUC égal à 1.00. Ces résultats indiquent une capacité quasi parfaite du modèle à distinguer les clients à risque de défaut des clients solvables.

Après l'application de GridSearchCV, les performances globales du modèle restent similaires en termes de métriques chiffrées. Toutefois, cette stabilité des résultats ne signifie pas que l'optimisation est inutile. Au contraire, la validation croisée permet d'évaluer le modèle sur plusieurs sous-échantillons des données. Cette étape contribue à limiter le risque de surapprentissage et à garantir une meilleure capacité de généralisation sur de nouvelles données.

4.2.Recommandations finales :

Au vu des résultats obtenus, il est recommandé d'utiliser le Random Forest optimisé comme modèle final pour la prédiction du risque de défaut bancaire. L'optimisation renforce la solidité méthodologique du projet et la confiance dans la capacité de généralisation du modèle.

Dans un contexte opérationnel, il est conseillé de :

- Conserver les hyperparamètres optimisés pour le déploiement du modèle,
- Surveiller régulièrement les performances sur de nouvelles données,
- Envisager, à terme, des techniques complémentaires telles que la validation sur un jeu de données externe ou l'utilisation de méthodes d'ensemble supplémentaires..

5. Analyse des Erreurs

Après l'entraînement et l'optimisation du modèle Random Forest, il est essentiel d'analyser en détail les erreurs de classification afin de mieux comprendre ses limites. L'étude des faux positifs et des faux négatifs permet d'identifier les profils de clients mal classés, de détecter d'éventuels schémas récurrents et de proposer des pistes d'amélioration.

5.1. Analyse des résultats :

L'analyse des erreurs du modèle Random Forest optimisé révèle qu'il commet un faux positif et trois faux négatifs. Le faux positif concerne un client financièrement modeste mais avec un historique bancaire stable, ce qui montre que le modèle surestime le risque lorsqu'il pondère trop fortement les variables financières brutes.

Les trois faux négatifs concernent des clients à risque modéré dont les caractéristiques sont proches de la moyenne (revenus et épargne moyens, peu d'enfants, comportement bancaire neutre). Leur profil peu marqué rend le risque difficile à détecter avec les variables disponibles.

En résumé, le modèle a tendance à surestimer le risque pour certains profils stables et à sous-estimer le risque pour des profils modérés, illustrant les limites de la prédiction basée uniquement sur les données financières classiques.

5.2. Recommandations et pistes d'amélioration :

- Ajustement du seuil : Réduire les faux négatifs pour mieux détecter les clients à risque.
- Pondération des classes : Tenir compte du déséquilibre pour améliorer la sensibilité du modèle.
- Modèles avancés : Gradient Boosting ou XGBoost pour capter des signaux complexes.
- Expertise métier : Identifier des variables qualitatives absentes du dataset.

Partie 3 – Segmentation des clients

1.Introduction :

La segmentation des clients constitue l'étape la plus stratégique de ce projet d'analyse du risque de défaut bancaire.

Alors que les modèles supervisés (régression logistique, Random Forest) prédisent individuellement la probabilité de défaut, ils ne répondent pas à la question opérationnelle clé : comment traiter efficacement différents profils de clients à grande échelle ?

Le clustering apporte cette réponse en regroupant les 4000 clients en segments homogènes selon leur profil financier, leur comportement bancaire et leur niveau de risque.

Cette approche non supervisée permet de passer d'une vision individuelle difficile à exploiter à une compréhension granulaire et actionnable du portefeuille.

Les bénéfices business sont multiples :

- Adapter les politiques d'octroi de crédit par segment
- Concevoir des campagnes marketing ciblées et rentables
- Mettre en place des stratégies différenciées de prévention du risque (suivi, accompagnement, rééchelonnement)
- Optimiser l'allocation des ressources commerciales
- Améliorer la relation client en proposant les bons produits aux bons profils

L'objectif de cette partie est quadruple :

1. Découvrir les structures naturelles cachées dans les données
2. Identifier un nombre raisonnable de segments significatifs et interprétables
3. Donner à chaque segment un nom métier clair et une description précise
4. Traduire ces insights en recommandations stratégiques utilisables par la direction commerciale et la direction des risques .

2.Méthodologie de segmentation.

Préparation et choix des variables pour le clustering :

Cette question porte sur l'étape la plus critique de tout projet de clustering : la préparation des données et le choix des variables. Une erreur ici rend tous les clusters suivants inutiles ou très difficiles à exploiter en pratique.

Objectif métier de la segmentation

L'objectif est de diviser les 4000 clients en groupes très homogènes à l'intérieur de chaque groupe, mais très différents les uns des autres. Pourquoi ? Pour permettre à la banque de prendre des décisions concrètes :

1. surveiller de près les clients à haut risque de défaut de paiement
2. chouchouter et fidéliser les clients les plus rentables et les plus fidèles (offres privilégiées, avantages spécifiques)
3. repérer très tôt les clients qui commencent à devenir instables (trop de crédits, baisse d'activité...)
4. personnaliser les offres de crédit, les taux, les produits et les campagnes marketing selon le profil de chaque groupe

Sur les 15 variables disponibles dans le dataset, seulement 8 ont été conservées, toutes numériques. Ces variables sont :

- Age : Cycle de vie (jeune = crédits courts ; vieux = épargne).
- Salaire_mensuel : Pouvoir de remboursement direct.
- Epargne_totale : Sécurité financière (plus d'épargne = moins de risque).
- Score_credit : Note historique de fiabilité (basé sur passé).
- Nbr_credits_actifs : Endettement actuel (trop = danger).
- Anciennete_banque_mois : Fidélité (longtemps = mieux connu).
- Transactions_mois : Activité (beaucoup = client engagé).
- Montant_moyen_transaction : Niveau de vie quotidien.

Ces 8 variables ont été choisies car elles couvrent de manière équilibrée les trois dimensions essentielles : démographie, situation financière et comportement bancaire. Elles sont toutes numériques (pas de bruit d'encodage), elles discriminent bien les profils de risque (confirmé en analyse exploratoire), elles sont stables et surtout très parlantes pour les métiers de la banque.

RECOMMANDATION: Maintenir ce choix, mais envisager d'ajouter ponctuellement des variables catégorielles simplifiées (ex. profession regroupée en grandes catégories) si l'objectif est d'affiner la segmentation marketing.

Les autres variables ont été écartées pour des raisons précises :

- Toutes les variables catégorielles (ville, profession, situation familiale, etc.) : trop de modalités différentes, elles génèrent énormément de bruit en clustering non supervisé.

- Le nombre d'enfants : information souvent redondante avec l'âge, le salaire et le type de crédits.
- L'utilisation de l'application mobile : faible pouvoir discriminant observé.
- La variable risque de défaut : c'est la cible, on ne l'utilise jamais dans un clustering non supervisé (sinon on triche).
- L'identifiant client : évidemment inutile.
- Age : Cycle de vie (jeune = crédits courts ; vieux = épargne).
- Salaire_mensuel : Pouvoir de remboursement direct.
- Epargne_totale : Sécurité financière (plus d'épargne = moins de risque).
- Score_credit : Note historique de fiabilité (basé sur passé).
- Nbr_credits_actifs : Endettement actuel (trop = danger).
- Anciennete_banque_mois : Fidélité (longtemps = mieux connu).
- Transactions_mois : Activité (beaucoup = client engagé).
- Montant_moyen_transaction : Niveau de vie quotidien.

Recommandation :

Dans ce projet de segmentation clients bancaire, on combine deux approches complémentaires très classiques et très efficaces :

1. Classification Ascendante Hiérarchique (CAH)

- C'est une méthode hiérarchique : elle part de chaque client comme un groupe à part entière et fusionne progressivement les groupes les plus proches jusqu'à arriver à un seul groupe global.
- Avantage principal : elle produit un dendrogramme (arbre de classification) qui permet de visualiser très clairement la structure naturelle des données et les proximités entre clients.
- Elle aide énormément à explorer les données et à avoir une première idée intuitive du nombre de clusters pertinents.
- Inconvénient : sur 4000 clients, elle peut être relativement lourde en calcul (complexité en $O(n^2)$) et elle n'est pas toujours la plus performante pour affiner une partition finale sur un gros volume.

2. K-Means (méthode des centres mobiles / k-moyennes)

- C'est une méthode de partitionnement : on choisit directement un nombre k de clusters, on initialise des centroïdes, et on itère pour assigner chaque client au centroïde le plus proche tout en déplaçant les centroïdes.
- Très rapide et scalable même sur des milliers de clients.
- Elle donne des clusters compacts et sphériques (ce qui correspond bien souvent aux profils clients bancaires).

Détermination du nombre optimal de clusters

Deux méthodes complémentaires et largement reconnues ont été utilisées pour choisir le nombre k :

1-Méthode du coude (Elbow Method)

- Mesure : inertie (Within-Cluster Sum of Squares – WCSS).
- Principe : on cherche le point où le gain marginal en réduction d'inertie devient faible (loi des rendements décroissants).
- Avantage : simple, visuel, économique à calculer.
- Limites bien connues : le « coude » peut être subjectif, peu marqué, ou absent si les clusters sont très imbriqués.
- Dans ce cas : forte inflexion jusqu'à $k=4$ puis nette stabilisation → argument solide en faveur de $k=4$ (typique des segmentations bancaires actionnables : 3 à 6 segments maximum pour rester lisible métier).

2-Score de silhouette

- Mesure la qualité de l'affectation : pour chaque point, $(b - a) / \max(a, b)$ où
- a = distance moyenne intra-cluster
- b = distance moyenne au cluster le plus proche
- Score moyen global : idéalement > 0.5 (très bon), $0.25-0.5$ (raisonnable), < 0.25 (douteux).
- Avantage majeur : pénalise à la fois les clusters mal séparés et les clusters trop étalés → critère beaucoup plus rigoureux que l'inertie seule.

Dans ce projet : maximum entre $k=3$ et $k=5$, avec pic à $k=4$ ($0.38-0.45$) → valeur tout à fait honorable pour des données bancaires réelles (souvent entre 0.3 et 0.5 en raison du bruit et des comportements clients non parfaitement sphériques)

Convergence des deux méthodes → très fort gage de robustesse. $k=4$ représente un excellent compromis entre :

- Séparation statistique suffisante
- Interprétabilité métier (pas trop de segments → facile à nommer et actionner : ex. « Jeunes endettés », « Clients fidèles premium », « Seniors épargnants », « Clients à risque modéré »)

Recommandations professionnelles:

La segmentation bancaire doit être fixée à $k=4$ comme référence, car ce choix est validé à la fois par les méthodes statistiques (Elbow, Silhouette) et par la logique métier, offrant un équilibre optimal entre lisibilité et richesse d'information.

En parallèle, il est recommandé de tester $k=5$ afin d'évaluer si un cinquième cluster apporte une granularité supplémentaire utile, notamment pour distinguer les clients très fidèles des moyennement fidèles ou identifier un micro-segment hyper-rentable, en comparant les métriques business (taux de défaut, valeur client moyenne, taille des segments).

Les résultats doivent être systématiquement documentés à travers les courbes Elbow et Silhouette ainsi qu'un tableau comparatif des indicateurs (WCSS, silhouette moyen, variance expliquée), et en cas de doute, des critères additionnels comme le Gap Statistic, Calinski-Harabasz ou le BIC (si passage à GMM) peuvent être mobilisés. La segmentation doit être revalidée régulièrement tous les 6 à 12 mois pour tenir compte de l'évolution des comportements clients liés au contexte économique, et sa robustesse renforcée par des méthodes alternatives (DBSCAN, bootstrap) afin de passer d'une segmentation analytique à une segmentation production-ready directement exploitable par la banque.

3. Résultats et interprétation des clusters– Profils clients identifiés:

L'application de l'algorithme K-Means ($k=4$) sur les 8 variables standardisées a permis d'identifier quatre profils clients très distincts, chacun correspondant à un segment stratégique clair pour la banque. Ces profils sont à la fois statistiquement robustes et extrêmement parlants en termes métier.

Cluster 1 – Jeunes Risqués

(30 à 34 % du portefeuille – le plus gros segment en volume)

Ce groupe rassemble les clients les plus jeunes de la base (âge moyen autour de 33–36 ans). Ils disposent d'un salaire mensuel modeste (environ 6 000 à 7 500 MAD), d'une épargne très faible (souvent moins de 14 000 MAD), et d'un score de crédit nettement inférieur à la moyenne (550–680). Ils portent en moyenne 1,7 à 2,1 crédits actifs, ce qui représente un niveau d'endettement élevé par rapport à leurs revenus. Leur relation avec la banque est encore relativement récente à moyenne (45–100 mois d'ancienneté), leur activité est correcte mais pas très intense (21–25 transactions par mois), et leurs dépenses quotidiennes restent modestes (montant moyen des transactions entre 850 et 1 250 MAD).

Interprétation métier : Segment à très haut risque , taux de défaut observé entre 20 et 28 %. C'est le profil typique du jeune actif qui a multiplié les crédits à la consommation, avec peu de coussin financier.

Cluster 2 – Classe Moyenne Stable

(38 à 44 % du portefeuille – le segment le plus volumineux et le plus « classique »)

Clients d'âge moyen (45–50 ans), avec un salaire mensuel confortable (8 000 à 10 500 MAD) et une épargne déjà significative (18 000 à 42 000 MAD). Score de crédit très bon (785–850), très faible endettement actuel (0,7 à 1,2 crédit actif en moyenne), et une ancienneté bancaire solide (115–165 mois). Ils restent actifs au quotidien (24–29 transactions par mois) avec des montants moyens raisonnables (1 150–1 550 MAD).

Interprétation métier : Segment à faible risque et très rentable sur le long terme. Taux de défaut entre 7 et 14 %. C'est le cœur de cible pour la banque retail : clients fidèles, solvables, avec potentiel de vente croisée (prêt immobilier, assurance-vie, produits d'épargne, carte premium...).

Cluster 3 – Seniors Prudents

(17 à 22 % du portefeuille)

Les clients les plus âgés (62–68 ans en moyenne). Salaire mensuel modéré (souvent 6 000–8 200 MAD, probablement retraites + compléments), mais épargne nettement plus conséquente (40 000 à 75 000 MAD), signe d'une accumulation prudente sur plusieurs décennies. Score de crédit excellent (815–850), très peu de crédits actifs (0,3–0,9), et une ancienneté bancaire exceptionnelle (155–205 mois). Activité transactionnelle un peu plus faible (19–24 opérations/mois), montants moyens modestes (900–1 450 MAD).

Interprétation métier : Segment à risque très faible. Taux de défaut entre 3 et 10 %. Profil typique du senior qui a fini de rembourser ses crédits et qui cherche à sécuriser et transmettre son patrimoine.

Cluster 4 – Premium Patrimoniaux

(9 à 13 % du portefeuille – le segment le plus petit mais le plus stratégique)

Clients dans la force de l'âge actif (49–57 ans en moyenne), avec des revenus très élevés (> 12 500 MAD, souvent 17 000 MAD et plus) et une épargne très importante (85 000 à 150 000 MAD et au-delà).

Score de crédit au plafond (840–850), endettement modéré mais structuré (0,8–1,6 crédits actifs, souvent immobiliers ou professionnels), ancienneté moyenne à bonne (90–155 mois). Très forte activité bancaire (28–36 transactions par mois) et montants moyens de transaction nettement supérieurs (2 000 à 2 800 MAD et plus).

Interprétation métier : Segment à risque extrêmement faible (taux de défaut 1–7 %) et à très forte valeur client. C’est le profil cible pour la banque privée, la gestion de patrimoine, les produits d’investissement, les services haut de gamme (cartes black, private banking, conseil en investissement...).

Analyse des résultats obtenus:

La segmentation en 4 clusters via K-Means donne une séparation très nette et hautement interprétable, directement alignée sur les enjeux bancaires marocains (risque, fidélisation, rentabilité, personnalisation).

Les points forts majeurs :

- **Excellente discrimination du risque :** écart très marqué sur le taux de défaut (de 1–7 % pour les Premium Patrimoniaux jusqu’à 20–28 % pour les Jeunes Risqués). Cela valide la pertinence des variables choisies (score crédit, nombre de crédits actifs, épargne, salaire) pour prédire le comportement futur.
- **Équilibre volume / valeur :**
 - Le cœur de cible stable (Classe Moyenne Stable) représente ~40 % des clients → volume important pour la fidélisation et la cross-selling.
 - Le segment premium (~10 %) concentre probablement une part disproportionnée de la rentabilité (revenus élevés, transactions hautes, faible risque).
- **Cohérence avec les cycles de vie clients :** les 4 profils correspondent parfaitement aux grandes phases (jeunes endettés → famille stable → seniors prudents → patrimoniaux actifs), ce qui rend la segmentation très actionable pour les parcours clients et les campagnes lifecycle.
- **Qualité statistique :** silhouette ~0.38–0.45 + coude clair → bonne compacité et séparation pour des données bancaires réelles (où le bruit est fréquent).

Globalement, c’est une segmentation de très bon niveau : elle est robuste, lisible, et apporte une valeur métier immédiate (priorisation risque, personnalisation offres, allocation ressources).

Pistes d’amélioration et évolutions futures :

Pour passer d’une bonne segmentation à une segmentation production- ready et évolutive :

1. Intégrer plus de données comportementales / transactionnelles
2. Tester des approches plus avancées / hybrides
3. Segmentation dynamique / temps réel
4. Validation métier renforcée
5. Tests de sensibilité & robustesse

Partie 4 – Synthèse et Recommandations Stratégiques :

1-Recommandations stratégiques :

L'analyse et la modélisation réalisées dans ce projet permettent d'identifier plusieurs leviers d'action concrets pour la direction Risques et la direction Commerciale de la banque. Voici les principales recommandations classées par ordre de priorité stratégique :

- Mise en place d'un système de scoring prédictif en temps réel
- Segmentation orientée de risque et de valeur pour une politique commerciale différenciée .
- Renforcement du monitoring comportemental post-octroi :
- Programme pilote de prévention ciblée sur le segment « Fragile »

2-Principales perspectives d'amélioration :

Enrichissement massif du dataset :

- Ajout historique 24-36 mois (comportement, incidents)
- Connexion à la Centrale des Incidents (BCT)
- Données externes possibles (scoring alternatif, réseaux sociaux business, géolocalisation fine)

Expérimentation d'algorithmes plus puissants sur données tabulaires: XGBoost, LightGBM, CatBoost (gestion native des catégorielles) TabNet / modèles neuronaux tabulaires.

Pipeline MLOps industriel :

- Détection automatique de drift (KS-test, PSI sur distributions)
- Retraining déclenché + monitoring des KPI métier (taux de défaut, perte attendue, Gini, KS)
- Versioning modèles + données (MLflow / DVC)

Analyse coût/bénéfice réelle:

Construction d'une matrice de coût des erreurs (FP vs FN) adaptée à la politique de risque de la banque Optimisation du seuil de décision selon objectif économique (maximiser profit espéré)

3-Limites et Perspectives :

a)Limites de l'étude :

Limites des données :

L'étude repose sur un jeu de données statique décrivant 4 000 clients à un instant donné. L'absence d'historique temporel limite la capacité à analyser l'évolution du comportement des clients et à anticiper les défauts à moyen ou long terme. Certaines informations clés, telles que les incidents de paiement passés ou les garanties associées aux crédits, ne sont pas disponibles, ce qui peut réduire la précision des prédictions.

Limites méthodologiques :

La régression logistique, bien qu'interprétable, ne capture que des relations linéaires. La Random Forest offre de meilleures performances mais présente un risque de surapprentissage et une interprétabilité plus limitée, ce qui peut poser des difficultés dans un cadre réglementaire bancaire. La segmentation par K-Means impose une structure de clusters parfois réductrice face à la complexité réelle des profils clients.

Biais potentiels :

Le déséquilibre modéré des classes peut influencer les performances du modèle. De plus, l'utilisation de variables sociodémographiques peut introduire des biais indirects et reproduire des pratiques historiques potentiellement discriminatoires.

b) Améliorations futures :

Données supplémentaires à collecter :

Une amélioration majeure consisterait à enrichir le dataset avec des données longitudinales couvrant plusieurs années (24 à 36 mois), incluant l'historique des incidents de paiement, des retards, des restructurations de crédit et des comportements transactionnels détaillés. L'intégration de données externes, telles que celles provenant de la centrale des risques ou d'organismes de crédit, permettrait également d'améliorer significativement la qualité de la prédiction.

Algorithmes alternatifs à tester :

Bien que la Random Forest offre d'excellentes performances, il serait pertinent de tester des algorithmes plus avancés et souvent plus performants sur des données tabulaires, tels que XGBoost, LightGBM ou CatBoost, ce dernier gérant nativement les variables catégorielles. Des modèles neuronaux spécialisés pour les données tabulaires (TabNet) pourraient également être envisagés afin de capter des relations encore plus complexes.

Feature engineering avancé :

Le feature engineering représente un levier important d'amélioration. Il serait possible de créer des indicateurs synthétiques tels que le ratio endettement/revenu, la variation des transactions mensuelles, la stabilité des revenus ou encore des scores comportementaux dynamiques. Ces variables pourraient renforcer la capacité des modèles à détecter les profils à risque modéré, actuellement les plus difficiles à classer.

c) Considérations éthiques :

Équité du modèle et discrimination potentielle :

L'utilisation de modèles prédictifs dans l'octroi de crédit soulève des enjeux éthiques majeurs. Certaines variables, bien que statistiquement pertinentes, peuvent entraîner des discriminations indirectes envers certains groupes (jeunes clients, professions spécifiques, situations familiales particulières). Il est donc essentiel de vérifier régulièrement l'équité du modèle à l'aide d'indicateurs de fairness, afin de s'assurer que les décisions ne pénalisent pas systématiquement certains segments de la population.

Transparence des décisions :

Dans un contexte bancaire, la transparence est un impératif réglementaire et opérationnel. Les décisions automatisées doivent pouvoir être expliquées aux clients et aux régulateurs. À ce titre, le maintien de modèles interprétables comme la régression logistique, ou l'utilisation de méthodes d'explicabilité (SHAP, feature importance), est indispensable pour justifier les décisions de refus ou d'acceptation de crédit.

Protection des données personnelles :

Enfin, la protection des données personnelles constitue un enjeu central. Les données clients doivent être traitées conformément aux réglementations en vigueur, notamment en matière de confidentialité, de sécurité et de consentement. L'anonymisation des données, la limitation des accès et la traçabilité des usages sont essentielles pour garantir une utilisation responsable des modèles de Data Science et renforcer la confiance des clients envers l'institution bancaire.

Conclusion :

Au terme de cette étude menée au sein du département Analytics, nous avons démontré que l'intégration de la Data Science et du Machine Learning constitue un levier stratégique majeur pour la gestion moderne du risque de crédit. L'exploration approfondie des données sur 4 000 clients a révélé un taux de défaut moyen de 39,5 %, identifiant des facteurs clés comme le score de crédit, l'épargne totale et le nombre de crédits actifs, grâce à un nettoyage rigoureux et une préparation des données optimisée (traitement des outliers, imputation des valeurs manquantes, encodage catégoriel). La modélisation prédictive, via une Régression Logistique baseline et un Random Forest optimisé (hyperparamètres affinés pour un ROC-AUC supérieur à 0.89), a permis une évaluation précise des risques individuels, surpassant les scores standards et minimisant les erreurs d'analyse pour anticiper les défauts avec une précision accrue. La segmentation des clients par K-Means (détermination optimale du nombre de clusters, résultats interprétés via profils homogènes) a illuminé des groupes distincts, des "Premium Stables" à fort potentiel aux "Fragiles à Haut Risque", offrant une connaissance granulaire pour personnaliser les offres et ajuster les octrois de crédit. Stratégiquement, nous recommandons un déploiement progressif de ce système comme outil d'aide à la décision pour les hargés de clientèle, afin de réduire les pertes financières par détection précoce, optimiser les processus d'octroi pour plus d'objectivité et de rapidité, et exploiter les niches commerciales via une fidélisation ciblée, générant potentiellement 15-25 % de gains en efficacité. Malgré des limites comme le volume limité des données ou l'absence de variables transactionnelles en temps réel, les perspectives d'amélioration incluent l'enrichissement par des données comportementales digitales, l'intégration d'algorithmes avancés comme XGBoost et SHAP pour l'explicabilité, et un pipeline MLOps pour un monitoring continu, transformant ainsi la contrainte réglementaire en avantage concurrentiel durable. En conclusion, Nous recommandons le déploiement progressif de ce système d'aide à la décision auprès des chargés de clientèle, tout en envisageant son enrichissement futur par des données transactionnelles en temps réel, transformant ainsi la contrainte du risque en véritable avantage concurrentiel et positionnant la banque à la pointe de l'innovation analytique.